Plan de aprendizaje desde cero — Investigación cuantitativa rigurosa

> **Fecha:** 2026-10-27 **Objetivo:** construir la base metodológica que permite distinguir un resultado real de un artefacto. **Duración:** 8-10 semanas a ~5 h/semana, o 4 semanas intensivas. **Requisito:** Python y pandas a nivel de uso diario. Estadística de instituto (media, desviación, correlación).

Principio cero

> **Valida tu herramienta con datos donde YA SABES la respuesta, antes de usarla con datos donde no la sabes.**

Es el principio que más veces salvó este proyecto: tres de los cuatro errores graves se detectaron porque un test sintético con respuesta conocida no daba lo que debía (un look-ahead que hacía que el azar ganara, un signo de drawdown invertido, un cap de pesos que no respetaba el límite).

Sin ese principio, un backtester con un bug **produce números plausibles durante meses**.

Cada nivel de este plan incluye un **test de respuesta conocida**. No es opcional: es la puerta de entrada al siguiente nivel.

Las tres reglas del curso

1. **Ningún resultado se interpreta sin su hipótesis nula.** Si no sabes qué saldría sin señal, no sabes qué significa tu resultado.
2. **Un resultado negativo es un entregable.** Se documenta con el mismo rigor que uno positivo.
3. **No se persigue alfa.** El curso es sobre método. Si en el camino aparece una señal, se anota y se prueba **después** del nivel 6, con las reglas del nivel 6.

Tampoco en este curso: modelos de machine learning (nivel posterior), datos de pago, ni capital real.

Nivel 0 — Los datos

Duración: 1 semana

Lo que vas a aprender

Un backtest es, antes que nada, una afirmación sobre unos datos. Si los datos mienten, todo lo demás sobra.

- Retorno **simple** vs **logarítmico**: cuándo usar cada uno y por qué suman distinto.
- **Precio vs total return**: splits, dividendos, y por qué dos series del mismo activo pueden diferir 2,6 pp/año.
- **Sesgo de supervivencia**: por qué un universo actual de S&P 500 no es el universo de 2018.
- **Datos point-in-time**: lo que sabías en la fecha t, no lo que se publicó después.
- **Huecos**: `ffill` , `bfill` y cómo el relleno hacia atrás mete el futuro en el pasado.

Ejercicio

Audita el dataset US de qlib (`~/.qlib/qlib_data/us_data`) y responde por escrito:

1. ¿Qué es exactamente `$close` ? ¿Y `$factor` ? ¿Cuál de los dos incluye dividendos?
2. ¿Cuántos tickers tienen historia completa en 2018-2026? ¿Cuántos entran y salen?
3. ¿Qué porcentaje de celdas son NaN? ¿Están concentrados en fechas o en tickers?
4. ¿El universo `sp500.txt` tiene sesgo de supervivencia? ¿Cómo lo comprobarías?
5. Calcula el dividend yield implícito del universo. ¿Coincide con el real?

Entregable

`nivel0_auditoria_datos.py` + `nivel0_informe.md` (1 página, con las respuestas y **tres riesgos concretos** que hayas identificado).

Test de respuesta conocida

Construye un precio sintético con:

- 2 splits conocidos (2:1 y 3:1)
- dividendo del 2% anual

Calcula el total return por dos caminos y comprueba que coincide con el que **tú mismo generaste**. Si tu método de ajuste no recupera el número que pusiste, el método está mal.

Sabes que lo tienes cuando...

Puedes explicar por qué dos series del mismo activo difieren 2,64 pp/año y en qué situación usarías cada una.

Nivel 1 — El motor de backtest

Duración: 2 semanas (es el nivel más largo, y el más importante)

Lo que vas a aprender

Vas a escribir tu propio backtester. **Sin qlib.** Unas 100-150 líneas.

La razón: usar una herramienta que no controlas es cómodo hasta que produce un número que no entiendes. Escribirla te obliga a decidir, y cada decisión es una fuente de error que aprenderás a reconocer.

- Pesos, rebalanceo, **turnover**
- Costes: comisión, spread, slippage, impacto
- Ejecución: ¿al cierre o a la apertura? ¿con retardo de un día?
- **Look-ahead** en la ejecución: el error de aplicar los pesos del día t al retorno del día t
- Capacidad: por qué una estrategia de 30 millones no escala a 3.000

Ejercicio

Implementa:

```
entrada:  precios (DataFrame fechas × tickers), calendario de pesos, coste en bps
salida:   serie de retornos diarios netos de costes
```

Sin mirar código ajeno. Cuando funcione, compáralo con una implementación independiente que escribas después.

Entregable

`motor_bt.py` con docstring explicando **cada decisión de diseño** y por qué.

Test de respuesta conocida

Cuatro comprobaciones, las cuatro obligatorias:

1. **Un solo activo, sin costes:** el retorno debe ser exactamente el del activo.
2. **Pesos constantes, sin costes:** debe coincidir con la fórmula analítica de rebalanceo periódico.
3. **Turnover:** debe coincidir con la suma manual `0.5·Σ|w_nuevo − w_viejo|`.
4. **Truncamiento:** corta los datos en una fecha, recalcula, y comprueba que **el pasado no cambia** (diferencia < 1e-12).

La cuarta es la que detecta look-ahead. Si el pasado cambia al añadir futuro, tienes una fuga.

Sabes que lo tienes cuando...

Dos implementaciones independientes dan el mismo resultado, y el test de truncamiento pasa en verde.

Nivel 2 — Estadística para muestras pequeñas

Duración: 1-2 semanas

Lo que vas a aprender

El nivel que explica por qué casi todos los backtests publicados son falsos.

- **Independencia**: por qué 556.582 filas pueden ser 17 observaciones
- **Tamaño efectivo de muestra**: cómo contarlo de verdad
- **Error estándar e intervalo de confianza**: qué significa "IC = 0,032 ± 0,05"
- **Solapamiento**: labels de 120 días comparten 119 días; el t se infla
- **Potencia**: `n ≈ (t/r)²` — cuántas observaciones necesitas antes de empezar

Ejercicio

Implementa una función que, dada una señal y un retorno futuro, devuelva:

- IC (correlación de rango, por fecha, en sección cruzada)
- Intervalo de confianza **honesto** (no el clásico inflado)
- t corregido por solapamiento
- El **n efectivo**, no el n aparente

Entregable

`estadistica.py`

Test de respuesta conocida

Genera 1.000 datasets donde **tú impones** que el IC sea 0,05. Entonces:

1. La media de los IC estimados debe rondar 0,05 (insesgado).
2. En el **95%** de los casos, el IC verdadero debe caer dentro del intervalo de confianza que calculaste. Si cae solo en el 60%, tu intervalo es demasiado estrecho — que es exactamente el error a evitar.
3. Con labels solapados, el t clásico debe inflarse y el tuyo no.

Sabes que lo tienes cuando...

Puedes responder **antes de medir**: *"con estos datos, el efecto más pequeño que puedo detectar es X. Si el efecto real es menor, no concluiré nada."*

Nivel 3 — La hipótesis nula

Duración: 1-2 semanas

Lo que vas a aprender

El concepto que faltaba en todo el proyecto anterior.

- **Distribución nula**: qué resultados salen cuando NO hay señal
- **Bootstrap y block bootstrap**: remuestrear preservando la estructura (volatility clustering)
- **Permutación**: romper la relación señal-resultado y ver qué queda
- **p-valor**: qué mide y qué no mide
- **Múltiples comparaciones**: `1 - 0,95^k`. Con 30 intentos, 79% de falso descubrimiento.
- **Deflated Sharpe**: corregir el Sharpe por el número de intentos

Ejercicio

El experimento central del curso:

1. Genera **200 mercados sintéticos** por block-bootstrap de los retornos reales del universo. En ellos **no hay señal por construcción**.
2. Corre en cada uno una estrategia de selección (top-30 por cualquier criterio).
3. Guarda la distribución de Sharpes resultante.

Entregable

`calibracion_nula.py` + histograma + las tres conclusiones por escrito.

Test de respuesta conocida

Sobre datos **puramente aleatorios**, tu test de significancia debe rechazar la hipótesis nula **~5% de las veces**, no 50%.

Si rechaza más, tu test está roto. Lo sabes sin ambigüedad, porque en datos aleatorios la respuesta correcta es conocida.

Sabes que lo tienes cuando...

Puedes decir: *"un Sharpe de X es lo normal por azar si he hecho K intentos. Mi resultado está por encima / dentro / por debajo de eso."*

Nivel 4 — Factores y atribución

Duración: 1 semana

Lo que vas a aprender

La diferencia entre **beta** (estar en el mercado) y **alfa** (habilidad).

- CAPM: retorno = alfa + beta · mercado + ruido
- Fama-French: añadir tamaño y valor
- Momentum como factor
- Regresión: qué significan los coeficientes, y el R^2
- **Descomposición**: cuánto de mi retorno se explica y cuánto sobra

Ejercicio

1. Construye los factores que puedas con datos gratuitos: mercado (^GSPC), tamaño (diferencia entre los pequeños y los grandes), y momentum.
2. Regresa los retornos de **cualquier** cartera contra ellos.
3. Responde: ¿cuánto es mercado? ¿cuánto es tamaño? ¿cuánto sobra?

Entregable

`atribucion.py` + una tabla de descomposición.

Test de respuesta conocida

- Una cartera que **es exactamente el mercado** debe dar: beta = 1,00, alfa = 0,00, R^2 = 1,00.
- Una cartera que es el mercado ×2 debe dar beta = 2,00.
- Una cartera aleatoria de 30 acciones debe dar alfa ≈ 0 **y beta ≈ 1**.

Si tu regresión no reproduce estos casos, está mal especificada.

Sabes que lo tienes cuando...

Antes de llamar "alfa" a un retorno, lo has descompuesto.

Nivel 5 — Validación temporal

Duración: 1 semana

Lo que vas a aprender

Por qué el k-fold estándar **rompe** con series temporales, y qué se usa en su lugar.

- Por qué no puedes mezclar aleatoriamente el pasado y el futuro
- **Walk-forward**: entrenar en el pasado, probar en el futuro
- **Purged CV**: eliminar las observaciones cuyos labels se solapan con el test
- **Embargo**: dejar un hueco entre train y test
- Por qué "dividir por número de filas" no es purgar nada

Ejercicio

Implementa purged CV con embargo y **demuéstralo**:

1. Genera datos donde la relación señal-retorno sea **cero** por construcción.
2. Con k-fold ingenuo, el IC debe salir **inflado** (positivo).
3. Con purged CV + embargo, debe salir **≈ 0**.

Si tu purged CV no corrige el sesgo, no está purgando.

Entregable

`purged_cv.py`

Test de respuesta conocida

El del punto 2-3. Es un test perfecto porque conoces la respuesta: cero.

Sabes que lo tienes cuando...

Puedes mirar cualquier script de validación y decir si realmente purga o solo lo aparenta.

Nivel 6 — El protocolo de investigación

Duración: 1 semana

Lo que vas a aprender

El nivel que convierte el conocimiento técnico en investigación.

- **Pre-registro**: escribir la hipótesis y el criterio de decisión **antes** de mirar los datos
- **Hipótesis nula obligatoria** en cada test
- **Registro de intentos**: contar cuántas variantes se prueban
- **Holdout**: reservar datos y no tocarlos
- **Resultados negativos**: cómo se documentan

Ejercicio

Coge **una** hipótesis. Escribe su pre-registro:

```
## Hipótesis 001

**Predicción:** [qué espero]
**Datos:** [universo, periodo, frecuencia]
**Test:** [exactamente qué voy a medir]
**Hipótesis nula:** [contra qué me comparo]
**Criterio de éxito:** [qué número me haría adoptarla]
**Criterio de abandono:** [qué número me haría descartarla]
**Número de variantes que probaré:** [N, y no más]
**Fecha de pre-registro:** [antes de ejecutar]
```

Después ejecútala **una sola vez** y documenta el resultado, sea cual sea.

Entregable

`hipotesis/001_*.md` con el pre-registro y el resultado.

Test de respuesta conocida

Aquí el test no es técnico: **el criterio de abandono estaba escrito antes del resultado**. Si lo ajustaste después, has fallado el nivel.

Sabes que lo tienes cuando...

Puedes entregar un resultado negativo sin sentir que has perdido el tiempo.

Calendario

Semana	Nivel	Entregable
1	0 — Datos	Auditoría + informe
2-3	1 — Motor de backtest	`motor_bt.py` + 4 tests
4-5	2 — Estadística	`estadistica.py` + cobertura 95%
6-7	3 — Hipótesis nula	`calibracion_nula.py` + histograma
8	4 — Factores	`atribucion.py` + descomposición
9	5 — Validación temporal	`purged_cv.py`
10	6 — Protocolo	`hipotesis/001_*.md`

Si un nivel se alarga, se alarga. **No se salta el test de respuesta conocida.**

Lecturas

Cómo usar esta sección

Una regla: lee la lectura del nivel **cuando empiezas el nivel**, no antes. Leer sobre purged CV sin haber escrito un backtester es como leer un manual de escalada en el sofá.

Prioridad: las marcadas con ★ son las que de verdad cambian cómo piensas. Las demás son apoyo. Si tienes poco tiempo, ve solo a las ★.

Cómo leer un paper en 20 minutos:

1. Abstract y conclusión (2 min) → ¿qué afirma?
2. **Las figuras** (5 min) → casi siempre revelan más que el texto
3. Metodología (10 min) → ¿cómo lo mide? ¿qué supone?
4. Solo si te convence, el resto

Si el paper no responde "¿cuál es la hipótesis nula y qué la falsaría?", no es un paper de investigación: es marketing.

Nivel 0 — Datos

Lectura	Por qué
★ Documentación de qlib sobre `$close`, `$factor` y ajustes	Te tocó directamente: dos series del mismo activo con 2,6pp de diferencia
★ Hasbrouck, *Empirical Market Microstructure* (2007), cap. 1-3	De dónde salen realmente los precios: bid-ask, trades, y por qué "el precio de cierre" es una convención
Ernie Chan, *Quantitative Trading* (2009), cap. sobre datos	Práctico y honesto sobre las trampas típicas de datos gratuitos
Documentación de CRSP o Compustat (aunque no tengas acceso)	Verás qué es un dato *point-in-time* de verdad y por qué Yahoo no lo es

Ejercicio de lectura: busca en el paper de Hasbrouck la primera vez que aparece "bid-ask bounce" y entiende por qué un precio de cierre puede tener ruido que no es señal.

Nivel 1 — Motor de backtest

Lectura	Por qué
★ López de Prado, *Advances in Financial Machine Learning* (2018), cap. 1-2	Estructura de datos financieros, barras, y por qué el muestreo temporal no es trivial
★ Arnott, Harvey & Markowitz (2019), *A Backtesting Protocol in the Era of Machine Learning*, Journal of Financial Data Science	**El artículo más útil de toda la lista para tu caso.** Siete decisiones que hay que documentar en todo backtest
Ernie Chan, *Algorithmic Trading* (2013), cap. 1-2	Costes, slippage y capacidad con números concretos
Bailey, Borwein, López de Prado & Zhu (2014), *Pseudo-Mathematics and Financial Charlatanism*, Notices of the AMS	Divertido y brutal: cómo se fabrican resultados financieros con sobreajuste

---

Nivel 2 — Estadística para muestras pequeñas

Lectura	Por qué
★ Wasserman, *All of Statistics* (2004), cap. 6-8	Conciso y riguroso. Intervalos de confianza y tests sin rodeos
★ Lakens, *Improving Your Statistical Inferences* (libro libre online)	El mejor material didáctico sobre potencia, p-valores y por qué "no significativo" ≠ "no hay efecto"
Efron & Tibshirani, *An Introduction to the Bootstrap* (1993), cap. 1-6	La biblia del remuestreo. Los capítulos iniciales bastan
★ Ioannidis (2005), *Why Most Published Research Findings Are False*, PLoS Medicine	Por qué la comunidad científica entera tiene el problema que tú tuviste
Simmons, Nelson & Simonsohn (2011), *False-Positive Psychology*, Psychological Science	"Grados de libertad del investigador": cómo decisiones razonables producen falsos positivos. **Es tu proyecto, en psicología**

Ejercicio de lectura: en el paper de Simmons, cuenta cuántos "grados de libertad" reconoces de tu propio trabajo anterior.

Nivel 3 — Hipótesis nula y sobreajuste

Este es el nivel con la mejor literatura del campo. Casi todo es ★.

Lectura	Por qué
★ Bailey, Borwein, López de Prado & Zhu (2016), *The Probability of Backtest Overfitting*, Journal of Computational Finance	La formalización de "cuántos intentos he hecho"
★ Bailey & López de Prado (2014), *The Deflated Sharpe Ratio*, Journal of Portfolio Management	La corrección concreta: Sharpe ajustado por intentos, asimetría y curtosis
★ Harvey, Liu & Zhu (2016), *…and the Cross-Section of Expected Returns*, Review of Financial Studies	Por qué el umbral pasó de t=2,0 a t=3,0. Con datos de 300+ factores publicados
Harvey & Liu (2020), *False (and Missed) Discoveries in Financial Economics*, Journal of Finance	El reverso: también hay señales reales que descartamos por exigir demasiado

Lectura	Por qué
Nosek, Ebersole, DeHaven & Mellor (2018), *The preregistration revolution*, PNAS	Qué es pre-registrar y por qué cambió la ciencia

Orden recomendado: empieza por Bailey (2016) —es el más intuitivo—, sigue con el Deflated Sharpe, y deja Harvey para el final.

Nivel 4 — Factores y atribución

Lectura	Por qué
★ Ang, *Asset Management: A Systematic Approach to Factor Investing* (2014), cap. 1-4	La mejor exposición de beta vs alfa para alguien que viene de programar
★ Fama & French (1993), el paper de los tres factores	El original. Léelo aunque sea por encima: verás cómo se construye un factor de verdad
Jegadeesh & Titman (1993), *Returns to Buying Winners and Selling Losers*, Journal of Finance	El momentum original. 12 meses de formación, 3-12 de mantenimiento — y tú usaste 120 días con label 120
Daniel & Moskowitz (2016), *Momentum Crashes*, Journal of Financial Economics	Por qué el momentum se hunde en las recuperaciones. Explica 2021
★ Moreira & Muir (2017), *Volatility-Managed Portfolios*, Journal of Finance	El paper del vol-targeting que mediste. Verás qué encontraron ellos y con cuántos datos
Barroso & Santa-Clara (2015), *Momentum Has Its Moments*, JFE	Vol-scaled momentum: el Sharpe se dispara. Con datos de 1927, no de 8 años
Pedersen, *Efficiently Inefficient* (2015)	Catálogo de estrategias con su lógica económica. Útil para preguntarte "¿por qué existiría este alfa?"

Pregunta que debes saber responder tras este nivel: ¿por qué el momentum funciona en la literatura y no en tus datos? (Pista: universo, horizonte, y número de observaciones.)

Nivel 5 — Validación temporal

Lectura	Por qué
★ López de Prado, *Advances in Financial Machine Learning*, cap. 7	Purged CV y embargo. El capítulo que faltaba en tu script de agosto
López de Prado, *Advances in Financial Machine Learning*, cap. 11-12	Importancia de features y backtesting con múltiples caminos
López de Prado, *Machine Learning for Asset Managers* (2020)	Versión corta y aplicada del anterior

Ejercicio de lectura: después del cap. 7, vuelve a tu `momentum_purgedcv.py` y escribe en tres líneas por qué no purgaba.

Nivel 6 — Protocolo de investigación

Lectura	Por qué
★ Arnott, Harvey & Markowitz (2019), *A Backtesting Protocol…* (releer)	Ahora lo entenderás de verdad, con los niveles 1-5 hechos
★ Harvey & Liu (2015), *Backtesting*, Journal of Portfolio Management	Guía práctica de cómo NO reportar un backtest
Nosek et al. (2018), *The preregistration revolution* (releer)	Cómo adaptarlo a finanzas, donde no hay comité ético
Wilson et al. (2017), *Good Enough Practices in Scientific Computing*, PLOS Computational Biology	Cómo organizar código y resultados para que sean reproducibles por otro

---

Transversales — criterio, no técnica

Estas no enseñan métodos. Enseñan a **desconfiar**, que es más difícil.

Lectura	Por qué
★ Taleb, *Fooled by Randomness* (2001)	El libro que mejor explica por qué confundimos suerte con habilidad. Si solo lees uno de esta sección, este

Lectura	Por qué
★ Bernstein, *Against the Gods: The Remarkable Story of Risk* (1996)	Historia de cómo la humanidad aprendió a pensar en probabilidad. Contexto que no dan los manuales
Lowenstein, *When Genius Failed* (2000)	LTCM: dos premios Nobel, un modelo brillante, y una ruina. La arrogancia del modelo
Malkiel, *A Random Walk Down Wall Street*	El argumento escéptico, expuesto con claridad
Hamming, *The Art of Doing Science and Engineering* (1997), cap. sobre investigación	Cómo elegir problemas que merezcan la pena. Escrito para científicos, aplica igual
Box (1976), *Science and Statistics*, JASA	"Todos los modelos son falsos, pero algunos son útiles". Breve y fundacional

Cursos gratuitos

Curso	Nivel	Nota
MIT OCW 18.05, *Introduction to Probability and Statistics*	2	Sólido, con ejercicios y soluciones
Daniel Lakens, *Improving Your Statistical Inferences* (Coursera + libro libre)	2-3	El mejor sobre potencia y p-values. Directo al grano
Statistical Rethinking de McElreath (vídeos en YouTube)	optativo	Si te interesa la estadística bayesiana, la mejor pedagogía que existe

Qué NO leer (todavía, o nunca)

- **Blogs que prometen rentabilidades.** Si alguien publica un Sharpe de 3, la pregunta es cuántos intentos hizo. Casi nunca lo dice.
- **Papers de "X predice retornos"** sin mirar antes el t-stat y el número de observaciones independientes.
- **Tutoriales de ML aplicado a trading** antes del nivel 5. Enseñan a sobreajustar con mucha eficacia.
- **Listas de "los 10 factores que funcionan"** sin la corrección por múltiples comparaciones. Son el catálogo de falsos positivos del que habla Harvey.

Un consejo sobre el orden

Si te sientes perdido, este es el orden de impacto real:

1. **Arnott, Harvey & Markowitz (2019)** — cambia cómo diseñas cualquier test
2. **Taleb, *Fooled by Randomness*** — cambia cómo interpretas cualquier resultado
3. **Bailey et al. (2016), Backtest Overfitting** — te da el número
4. **Lakens** — te da la herramienta estadística
5. **Ang, *Asset Management*** — te da el marco beta/alfa

Los cinco, en ese orden, cubren el 80% de lo que hace falta para no engañarte.

Criterio de finalización

El curso está terminado cuando puedes hacer esto **sin ayuda**:

1. Dado un dataset, auditar su integridad y detectar 3 formas de fuga.
2. Dado un backtest ajeno, encontrar el look-ahead en menos de 10 minutos.
3. Dada una señal, decir **antes de medir** si el dataset permite concluir algo.
4. Dada una estrategia, construir su hipótesis nula.
5. Dado un retorno, descomponerlo en factores.
6. Dado un resultado positivo, calcular cuántos intentos lo invalidarían.

Y sobre todo: **entregar un resultado negativo con la misma calidad que uno positivo.**

Lo que este curso NO es

- No es una ruta para batir al mercado.
- No es una introducción a machine learning.
- No es una colección de tutoriales.

Es entrenamiento para **no engañarte a ti mismo con datos**. Que es más difícil de lo que parece, y más útil de lo que promete.

Plan creado el 2026-10-27. Cada nivel produce un artefacto reutilizable y verificable. El progreso no se mide por niveles leídos, sino por tests de respuesta conocida superados.